


FA3 : 跨 Warpgroup Pingpong 调度

示意时序（非等比例） | 1 个 producer WG + 2 个 consumer WG

A 跨 Warpgroup : turn[2] mbarrier 控制 WGMMMA 发射权

token : WG0.QK → WG1.QK → WG0.PV → WG1.PV → ...



B 单个 Consumer 内 : older QK + younger PV 的两级异步流水

Softmax 与 younger PV 的异步执行区间重叠



源码对应关系

发射令牌	pingpong_before / pingpong_after	turn[2] : 只串行化两个 consumer 的 WGMMMA commit 顺序
分数就绪	wgmma_wait_group<1>	等待 older QK ; 允许 younger PV 继续 in-flight
完全完成	wgmma_wait_group<0>	Softmax 后等待 PV 完成, 再释放当前 KV stage
双缓冲复用	stage_empty[2]	两个 consumer 都 arrive 后, producer 才能覆盖 K/V stage